Московский государственный технический университет им. Н.Э. Баумана Кафедра «Системы обработки информации и управления»

Лабораторная работа №2 по дисциплине «Методы машинного обучения» на тему

Выполнила:

студент Ли Лююй

группы ИУ5И-21М

Москва — 2024 г.

1. Цель лабораторной работы

Цель лабораторной работы: изучение продвинутых способов предварительной обработки данных для дальнейшего формирования моделей.

2. Задание

- 1. Выбрать набор данных (датасет), содержащий категориальные и числовые признаки и пропуски в данных. Для выполнения следующих пунктов можно использовать несколько различных наборов данных (один для обработки пропусков, другой для категориальных признаков и т.д.) Просьба не использовать датасет, на котором данная задача решалась в лекции.
- 2. Для выбранного датасета (датасетов) на основе материалов лекций решить следующие задачи:
 - 1.1.1 устранение пропусков в данных;
 - 1.1.2 кодирование категориальных признаков;
 - 1.1.3 нормализация числовых признаков.

3. Ход выполнения работы

import pandas as pd

from sklearn.impute import SimpleImputer

from sklearn.preprocessing import OneHotEncoder, StandardScaler

Чтение набора данных

Убедитесь, что путь к вашему набору данных и имя файла правильные

df = pd.read csv('generated dataset.csv')

Обработка пропущенных значений

Числовые признаки заполняются медианой

```
num_imputer = SimpleImputer(strategy='median')
num_columns = df.select_dtypes(include=['int64', 'float64']).columns
df[num_columns] = num_imputer.fit_transform(df[num_columns])
```

```
# Категориальные признаки заполняются наиболее частым значением
cat_imputer = SimpleImputer(strategy='most_frequent')
cat columns = df.select dtypes(include=['object']).columns
df[cat_columns] = cat_imputer.fit_transform(df[cat_columns])
# Кодирование категориальных признаков
encoder = OneHotEncoder(drop='first')
encoded_columns = encoder.fit_transform(df[cat_columns]).toarray()
encoded_df = pd.DataFrame(encoded_columns,
columns=encoder.get_feature_names_out(cat_columns))
# Объединение закодированных категориальных признаков с исходным набором данных и
удаление исходных категориальных столбцов
df = df.drop(cat columns, axis=1)
df = pd.concat([df, encoded df], axis=1)
# Стандартизация числовых признаков
scaler = StandardScaler()
df[num_columns] = scaler.fit_transform(df[num_columns])
# Экспорт обработанных данных в CSV
processed_dataset_path = 'processed_dataset.csv'
df.to_csv(processed_dataset_path, index=False)
print(f"数据预处理完成,文件'{processed_dataset_path}'已保存.")
Результат:
```

```
1processed_dataset.csv > 🛅 data
 UserID, Age, Income, Gender_Male, Gender_Non-Binary, Gender_Prefer not to say, Occupation_Docto
 0.16021520037340461,-0.011374757508619205,-0.8481379577085054,1.0,0.0,0.0,0.0,0.0,0.0,0.0,0.0
 -1.2687311813353392, -1.6992420007230695, 0.672949549390788, 0.0, 0.0, 1.0, 0.0, 0.0, 0.0, 1.0, 0.0
 0.2554782924873209,1.2361792918238006,-1.2656764360347754,0.0,0.0,0.0,0.0,0.0,1.0,0.0,0.0
 -1.5718410198796182, -0.011374757508619205, -0.19212712744188168, 1.0,0.0,0.0,0.0,0.0,0.0,0.0,0.0,0.0
 0.6018895365379254,0.7958660979417701,0.25719071548198336,0.0,0.0,1.0,0.0,1.0,0.0,0.0,0.0,0.0
 0.9569610616897951,-0.3049168867633062,-0.5389035539308398,0.0,1.0,0.0,0.0,0.0,1.0,0.0,0.0,0.0
 0.0043301405506325575,1.0894082271964571
 -1.4419368033606417, -0.378302419076978, - Col 3: Income 188, 1.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, 1.0
 0.4027030712088278,1.6764924857058312,-0.8254686776288876,0.0,0.0,0.0,0.0,0.0,0.0,0.0,1.0,0.0
 1.5371998954745578,0.8692516302554418,-0.585428543701719,1.0,0.0,0.0,0.0,0.0,0.0,0.0,1.0,0.0
```